

ДГТУ | Введение в машинное обучение

Донской государственный технический университет

Краткий учебный план дисциплины

Введение в машинное обучение

Рабочая версия

Параметр	Содержание
Уровень обучения	3 курс бакалавриата
Период	Октябрь–декабрь; экзамен в январе
Формат	Онлайн
Объём	15 лекций и 15 практических занятий по 2 академических часа; всего 60 академических часов
Итоговый контроль	Экзамен
Основные инструменты	Python, NumPy, Pandas, Matplotlib, scikit-learn, CatBoost, Jupyter Notebook, GitHub

Цель дисциплины

Сформировать у студентов фундаментальное понимание классического машинного обучения и базовые навыки решения задач на табличных данных — от постановки задачи и построения baseline до валидации, сравнения моделей и объяснения результатов.

Планируемые результаты обучения

- понимать назначение основных алгоритмов классического машинного обучения и объяснять их работу;
- корректно разделять данные, выбирать метрики и проводить валидацию моделей;
- обучать и сравнивать модели с помощью scikit-learn;
- выявлять переобучение, дисбаланс классов и утечки данных;
- проводить воспроизводимый ML-эксперимент и формулировать выводы;
- отвечать на базовые вопросы по Classical ML на собеседовании уровня Junior Data Scientist или ML Intern.

Организация учебной недели

Занятие	Назначение	Типовая структура
Лекция	Формирование понимания темы	Задача → интуиция → визуализация → математика → алгоритм → код → эксперимент → вопрос собеседования
Практика	Закрепление и применение материала	Разминка → совместный пример → самостоятельное решение → эксперимент → разбор ошибок → вывод
Самостоятельная работа	Проверка индивидуального понимания	Домашние задания, Kaggle, итоговый проект и подготовка к кvizам

Календарно тематический план

Одна лекция и одна практическая пара в неделю.

Неделя	Тема	Содержание лекции	Содержание практики
1	Введение в ML	Задачи ML, объект, признаки, target, supervised и unsupervised learning, общий ML pipeline	Настройка Jupyter, загрузка данных, первый train/test split, baseline
2	Данные и эксперимент	Типы признаков, EDA, train/validation/test, loss и metric, основы data leakage	EDA датасета, dummy baseline, таблица экспериментов, пример leakage
3	KNN	Расстояния, число соседей, scaling, curse of dimensionality, устройство fit и predict	KNN на NumPy, выбор k, scaling, сравнение со sklearn
4	Gradient Descent	Loss, производная, градиент, learning rate, batch, SGD и mini-batch	Реализация Gradient Descent, loss curve, эксперименты с learning rate
5	Linear Regression	Линейная модель, MSE, аналитическое и градиентное решения, MAE, RMSE, R^2	Linear Regression from scratch, метрики, выбросы, анализ коэффициентов
6	Регуляризация	Polynomial Features, сложность модели, Ridge, Lasso, ElasticNet, bias и variance	Полиномиальная регрессия, Ridge/Lasso, исследование alpha и переобучения
7	Logistic Regression	Sigmoid, вероятность, Maximum Likelihood, LogLoss, decision boundary	Sigmoid и LogLoss, Logistic Regression from scratch, predict_proba
8	Метрики классификации	Confusion matrix, precision, recall, F1, ROC-AUC, PR-AUC, threshold, imbalance	Расчёт метрик, ROC/PR curves, выбор threshold, class weights
9	Decision Tree	Жадное построение, Gini, entropy, information gain, сложность дерева	Поиск best split, визуализация дерева, влияние max_depth
10	Validation и tuning	K-Fold, Stratified K-Fold, learning curves, Grid Search и Randomized Search	Cross-validation, Pipeline, GridSearchCV, начало Kaggle
11	Bagging и Random Forest	Bootstrap, bagging, случайные признаки, ООВ, Extra Trees, feature importance	Сравнение Tree, Bagging, Random Forest и Extra Trees
12	Gradient Boosting	Последовательное исправление ошибок, отрицательный градиент, XGBoost, LightGBM, CatBoost	Упрощённый boosting, CatBoost, early stopping, продолжение Kaggle
13	SVM и kernels	Гиперплоскость, margin, support vectors, hinge loss, C, kernel trick, gamma	Линейный и RBF SVM, эксперименты с C, gamma и scaling

Неделя	Тема	Содержание лекции	Содержание практики
14	Признаки и Pipeline	Feature engineering, ColumnTransformer, Pipeline, leakage, importance, основы SHAP	Pipeline для смешанных данных, Leakage Challenge, ablation study
15	Unsupervised Learning	K-Means, DBSCAN, PCA, ограничения кластеризации, итоговая карта курса	K-Means from scratch, сравнение с DBSCAN, PCA, консультация по проекту

Система оценивания в разработке

Рейтинговая система и точное распределение баллов находятся в разработке. До утверждения документа приведённый ниже перечень отражает предполагаемые виды контроля без закрепления их удельного веса в итоговой оценке.

Вид работы	Что предполагается оценивать	Статус
Практические занятия	Работа на занятиях, корректность решения и содержательный вывод	В разработке
Домашние задания	Индивидуальные работы по основным разделам курса	В разработке
ML-квизы	Короткие проверки понимания ключевых понятий	В разработке
Мини-собеседования	Устные ответы по алгоритмам и прикладным ML-ситуациям	В разработке
Kaggle	Валидация, модели, эксперименты и итоговый отчёт	В разработке
Итоговый проект	Полный ML pipeline и краткая защита	В разработке
Экзамен	Теория, прикладная ML-ситуация и анализ результатов	В разработке

Домашние задания

Работа	Предварительная тема	Баллы
HW1	Первый корректный ML-эксперимент	Уточняются
HW2	KNN from scratch и scaling	Уточняются
HW3	Linear Regression, Gradient Descent и регуляризация	Уточняются
HW4	Logistic Regression, метрики и threshold	Уточняются
HW5	Decision Tree, Cross-Validation и Random Forest	Уточняются
HW6	Feature Engineering, Pipeline и Leakage Challenge	Уточняются

Работа	Предварительная тема	Баллы
HW7	Clustering и PCA	Уточняются

Основные правила оценивания

- Практика оценивается за выполненную работу, а не только за присутствие.
- Домашние задания выполняются индивидуально и сдаются через персональные GitHub-репозитории.
- Студент должен уметь объяснить любой фрагмент сданного решения.
- Использование AI-инструментов допускается при раскрытии способа использования и самостоятельной проверке результата.
- Точное количество работ, сроки, максимальные баллы и правила пересдачи будут утверждены отдельно.

Методический ориентир курса — «Тренировки по ML 1.0» Яндекса. Материалы курса адаптируются к университетскому формату и уровню подготовки студентов; структура и задания не копируются дословно.