Первая пара: курс, оценивание и введение в ML

Сценарий преподавателя. 90 минут. 31 слайд

Версия: 20 октября 2026. Порядок совпадает с основной HTML-презентацией. Восемь дополнительных слайдов находятся в appendix.html и не входят в обязательный маршрут.

Маршрут занятия

Минуты	Слайды	Блок
0-10	1-4	Знакомство и темы курса
10-17	5-6	Зачем нужна база ML
17-33	7-12	Баллы, задания и рейтинг
33-52	13-19	Введение и типы задач
52-72	20-25	Модели, переобучение и bias-variance
72-86	26-30	Проверка, утечки и полный маршрут
86-90	31	Итоги и вопросы

Перед парой

Подготовьте представление на 60-90 секунд. Запустите презентацию через локальный HTTP-сервер, проверьте формулы, стрелки и режим докладчика S. Пример рейтинга на слайде 12 вымышленный; ссылку на рабочую таблицу выдайте отдельно после её создания.

Критерии учебных медалей и частичного начисления 25/15 баллов публикуются до начала соревнований. Перед первым оцениваемым опросом проверьте Testportal на пробной попытке: 13 секунд на вопрос и блокировка при первом уходе со страницы.

1. Введение в машинное обучение

0-2 мин

Представьтесь: чем занимаетесь, почему ведёте курс. Если есть собственный ML-кейс, назовите задачу и полученный результат за 60-90 секунд. Сегодня: программа и польза курса, правила оценивания, затем первая вводная по ML. Не обещайте трудоустройство после одного курса.

2. Что вы сможете к концу семестра

2-5 мин

Обозначьте результат через действия студента. Например: получил таблицу, понял, что предсказывать, построил простое решение, честно оценил и объяснил его. Фокус курса - классическое ML; он создаёт базу для дальнейшего изучения нейросетей.

3. От данных к первым моделям

5-8 мин

Проведите аудиторию по темам курса без календаря: сначала формулируем задачу и учимся проверять качество, затем разбираем модели и способы обучения. Математику вводим по мере необходимости. Это маршрут курса, а не список тем сегодняшней пары.

4. От отдельных моделей к полному решению

8-10 мин

Продолжите маршрут: от отдельных моделей к ансамблям, затем к воспроизводимому эксперименту. Объясните связи между темами, не закрепляя их за неделями. Соревнования дадут возможность собрать изученное в самостоятельное решение.

5. Где нужна база машинного обучения

10-14 мин

Назовите четыре компании. Яндекс и SberDevices публикуют темы ML-секций. У Т-Банка есть отдельная страница интервью ML-инженеров. Для Авито ссылаемся на публичную матрицу компетенций DS, а не выдаём её за перечень вопросов собеседования. У junior указаны эксперименты с метриками, признаками и гиперпараметрами. Курс даёт базу, конкретная роль может требовать дополнительные знания. Официальные источники проверены 20.10.2026.

6. Что нужно уметь объяснять

14-17 мин

Это наши учебные примеры вопросов по перечисленным темам, не дословные вопросы конкретной компании. Не требуйте ответов сегодня. Пример для 99%: если мошеннических операций 1%, ответ «всегда обычная» даёт 99% accuracy и не находит мошенничество. Умение объяснить базу полезно и при выборе готовых решений в работе.

7. Базовый максимум за семестр: 100 баллов

17-21 мин

Проговорите каждую составляющую. Четыре опроса дают 20, два решения 50, две защиты 30. Это абсолютная сумма баллов, а не оценка относительно места одногруппника. Не обещайте дополнительные баллы за посещаемость или обычные практики: таких правил нет в документе курса. Источник: syllabus/grading_and_homework.md.

8. Два соревнования и две защиты

21-24 мин

На каждое соревнование приходится до 40 базовых баллов вместе с защитой. Место на публичном leaderboard не заменяет воспроизводимое решение и защиту. По возможности задачи будут разными: классификация и регрессия. Публичные notebooks допустимы с указанием источника; студент должен объяснить свои изменения и их эффект. Детальная рубрика частичного начисления баллов ещё не задана; опубликуйте её до старта каждой работы.

9. Четыре коротких опроса за курс

24-26 мин

Объясните правило до первого оцениваемого опроса. Попросите отключить уведомления и не переключать вкладки: потеря фокуса может фиксироваться платформой. До первого опроса преподаватель проверяет таймер и блокировку на пробной попытке. Не обещайте, что сервис запрещает системные скриншоты. Источник: syllabus/quiz_platform.md.

10. Как баллы переводятся в оценку

26-29 мин

Проверьте понимание границ: 60 - 2, 61 - 3, 76 - 4, 91 - 5. Не округляйте дробные баллы произвольно: интервалы заданы явно. На следующем слайде объясните бонусы. Источник: syllabus/grading_and_homework.md.

11. Учебные медали

29-31 мин

Это внутренние учебные медали курса, а не официальные медали Kaggle. Их критерии пока не определены: не называйте процентили, число призовых мест или минимальный score. Также до старта соревнования нужно опубликовать рубрику начисления неполных 25 и 15 баллов. Сохраняем уже записанные бонусы и правило золота. Источник: syllabus/grading_and_homework.md.

12. Все составляющие оценки видны в таблице

31-33 мин

Это демонстрационные данные, а не действующий рейтинг группы. Посчитайте строку Б вслух: 16+41+25+5=87, значит 4. Покажите, что студент видит, откуда берётся сумма. Для золота итоговая 5 выставляется по правилу медали независимо от суммы; в примере золотых медалей нет. Конкретная ссылка на рабочий рейтинг будет выдана отдельно, если таблица ещё не создана.

13. Что вообще делает машинное обучение?

33-36 мин

Правила и модели не противоположны абсолютно: обучение - тоже программа с заранее выбранным алгоритмом. Отличие в том, что конкретная зависимость определяется данными. Спросите: где всё-таки нужен человек? Ответ: постановка, данные, метрика, решение о применении.

14. Когда ML вообще уместен?

36-38 мин

После определения ML задайте вопрос «почему не просто if/else?». Если задача строго описывается коротким устойчивым правилом, нет смысла усложнять. ML полезен, когда зависимость сложна, есть данные и можно измерить выигрыш. Пример: проверка возраста по дате рождения - правило; оценка вероятности оттока - кандидат для ML. Подчеркните ограничения: сдвиг данных, приватность, стоимость ошибок.

15. Можно ли предсказать цену квартиры?

38-41 мин

Начните вводную с конкретной задачи: по сведениям о квартире предсказать цену. Попросите в чате назвать недостающие данные: район, состояние, дата, тип дома. Названия типов задач введём после примера. Выбор алгоритма не заменяет хорошую постановку.

16. Что модель получает при обучении

41-44 мин

Строка - объект. Площадь, этаж, район - признаки. Цена - целевая переменная. У новой квартиры цена неизвестна. Уточните, что реальный датасет требует обработки категориальных признаков, проверки пропусков и происхождения данных. Таблица только иллюстрирует постановку.

17. Есть правильный ответ для обучения?

44-47 мин

Сопоставьте с квартирой: известные цены прошлых сделок - учитель. Без target можно, например, искать группы похожих квартир. Это два режима обучения, а не две библиотеки. Кратко упомяните обучение с подкреплением: агент учится выбирать действия по награде; оно за пределами основного курса.

18. Ответ - число или категория?

47-50 мин

Дайте аудитории два контрастных примера и попросите определить тип. Формулы здесь лишь фиксируют тип результата: действительное число или один из конечного набора классов. Классификатор может также выдавать вероятности классов - это отдельно разберём позже. Если кто-то спрашивает про прогноз рейтинга 1-5, допустимы разные постановки; зависит от смысла и метрики.

19. Ищем структуру без целевой переменной

50-52 мин

Покажите разные цели без учителя: кластеризация, снижение размерности, поиск аномалий. Кластер - результат выбранных признаков и меры близости, а не заранее известный класс. K-Means и DBSCAN группируют объекты; PCA уменьшает число координат. Подробности на неделе 15. Обнаружение аномалий также бывает с учителем, если есть размеченные примеры.

20. Какую задачу здесь решают?

52-55 мин

Дайте минуту на ответы в чате до раскрытия фрагмента. Затем спросите не только название, но и признак решения: у А ответ числовой, у Б известные классы, у В меток нет. Если ответы расходятся, повторите слайд про обучение с учителем и без, а не двигайтесь дальше механически.

21. «Классификация» - задача, «дерево» - алгоритм

55-57 мин

Для спама можно попробовать логистическую регрессию, дерево, бустинг, нейросеть. Название задачи не диктует модель. И наоборот: KNN может решать и регрессию, и классификацию. Это частый источник путаницы у новичков. Спросите, может ли дерево предсказывать цену квартиры; ответ да - дерево регрессии.

22. Разные способы построить предсказание

57-59 мин

Короткий обзор механизмов, без вывода формул и сравнения победителей. Все эти семейства допускают варианты для регрессии и классификации. Обсудите один пример: KNN ищет похожие квартиры, дерево задаёт пороговые вопросы. Остальные методы разберём в соответствующих неделях.

23. Как модель учится на примерах

59-62 мин

Объясните смысл обучения без команд библиотеки. В качестве примера возьмите линейную модель цены по площади: сначала у неё неудачный наклон, затем алгоритм находит более подходящие коэффициенты. Функция потерь задаёт, какие ошибки штрафовать. Не каждый алгоритм буквально повторяет эти шаги: линейная модель может решать систему уравнений, дерево выбирает разбиения, KNN сохраняет примеры. Снижение ошибки на обучении ещё не гарантирует качества на новых квартирах.

24. Недообучение и переобучение

62-65 мин

Спросите, почему модель с нулевой ошибкой на учебных квартирах может оказаться бесполезной. При недообучении выбранная модель не улавливает существенную зависимость. При переобучении она использует случайные особенности обучающей выборки. Пример с одной ценой иллюстрирует слишком грубое решение для неоднородных квартир, а не утверждает, что константа всегда плоха. Разрыв ошибок также бывает из-за сдвига распределения. Следующий слайд объясняет механизмы через bias и variance.

25. Bias-Variance Tradeoff

65-72 мин

Предложите мысленный эксперимент: много раз собираем разные обучающие наборы одинакового размера из одного распределения и предсказываем цену одной и той же квартиры. Bias - отличие среднего прогноза от истинной средней цены при этих признаках. Variance - разброс прогнозов между такими обучениями. Грубая модель может стабильно ошибаться, гибкая - сильно реагировать на состав train. На схеме Bias² падает, variance растёт, их сумма с неустранимым шумом даёт ожидаемую квадратичную ошибку. Шум показан пунктирной горизонталью. Это иллюстрация типичного режима, не универсальный закон формы кривых. Не называйте variance разбросом цен квартир или ошибками одной модели. При переобучении пробуем ограничение глубины, регуляризацию или больше независимых данных; при недообучении - более выразительную модель и полезные признаки. Выбор проверяем на validation. Источники:
https://www.teach.cs.toronto.edu/~csc311notes/bias_variance_decomposition/bv.html и
https://scikit-learn.org/stable/auto_examples/ensemble/plot_bias_variance.html .

26. Успех на знакомых квартирах ещё не успех

72-75 мин

Аналогия: проверять студента по ответам, которые он только что заучил, бессмысленно для оценки переноса знаний. В реальной практике схемы разделения зависят от данных, времени и объёма выборки; здесь только принцип. Нельзя подбирать гиперпараметры по test. Позже вернёмся к этому подробно.

27. Утечка данных · Data Leakage

75-79 мин

Покажите четыре механизма утечки. Комиссия, равная проценту итоговой цены, косвенно раскрывает target. Действия клиента после даты прогноза раскрывают будущее. Копии одного объявления в разных выборках позволяют узнать учебный объект. Средние для заполнения пропусков и отбор признаков нельзя вычислять по всей выборке до split: validation и test начинают влиять на обучение. Если предсказываем для новых клиентов, делим по клиентам; если будущее - по времени. Связанные объекты опасны, когда такое пересечение не соответствует сценарию применения. Постоянный подбор модели по test тоже загрязняет оценку. Высокое качество само по себе не доказывает утечку.

28. Модель должна быть полезнее простого прогноза

79-82 мин

Медиану вычисляем только по train. Для MAE медиана - естественный константный baseline: она минимизирует сумму абсолютных отклонений на train. Попросите посчитать (1+2+1)/3 и назвать единицу измерения. Числа учебные. Модели сравниваем по validation, а test оставляем для финальной оценки выбранного решения. Средняя цена тоже возможный baseline; она оптимальна среди констант для квадратичной ошибки, не для MAE.

29. Параметр ≠ гиперпараметр

82-84 мин

Не погружайтесь в вывод линейной модели. Верхнее T - запись скалярного произведения. Спросите, что из примеров будет искать алгоритм, а что нужно выбрать до fit. В строгом смысле выбор гиперпараметров сам является процедурой настройки по данным, но это не внутренние параметры одной обученной модели. Test для такого выбора не используем.

30. Полный маршрут ML-решения

84-86 мин

Пройдите маршрут на квартире. Метрику и способ проверки определяем при постановке, до выбора модели; положение слова «метрика» в цепочке означает вычисление результата. Данные сначала разделяем, статистики preprocessing и baseline считаем на train. Повторное улучшение опирается на validation, test используем в конце. Baseline в сегодняшнем примере - медиана train.

31. Что разобрали сегодня

86-90 мин

Кратко свяжите разобранное в одну картину: сформулировали задачу, нашли признаки и target, выбрали тип задачи и обсудили обучение. Качество проверяем на новых данных, сравниваем с baseline и следим за утечками. Сложность выбираем с учётом недообучения и переобучения. Завершите ответами на вопросы аудитории.

Дополнительные материалы

В appendix.html сохранены: математическая цель supervised learning, обозначения выборки, эмпирический риск, кластер и класс, предположения моделей, K-Means/DBSCAN/PCA, ловушки split и выбор метрики. Расширенные математические объяснения доступны в редактируемом КОНСПЕКТ_ЛЕКЦИИ.tex.

Источники

Программа, система оценивания и правила опросов: документы syllabus/course_program.md, grading_and_homework.md и quiz_platform.md в репозитории курса.

Официальные описания отбора: Яндекс SberDevices, Т-Банк. Компетенции DS: Авито. Проверены 20 октября 2026. Учебные вопросы на слайде 6 не являются дословными вопросами компаний.