ДГТУ · Введение в машинное обучение

Пара 2
Линейная регрессия

Конспект для преподавателя к презентации Reveal.js

Главный вопрос пары: откуда берутся веса, если квадрат ошибки можно минимизировать точно, и какое число после этого ещё не является качеством?

90 минут · 27 слайдов · русскоязычная онлайн-лекция

Версия: октябрь 2026. Оценка качества — по учебнику Яндекса, статьи 1.3 и 3.1–3.3. Устройство МНК — в контуре лекций ВШЭ по линейным моделям и главы 3 ESL. Текст лекции эти источники не копирует.

Содержание

1 Педагогическая цель и маршрут **2**

2 Гальтон и имя метода **2**

3 Модель **3**

4 Вывод для одного признака **3**

5 Нормальные уравнения **4**

6 Три точки **5**

7 Геометрия **5**

8 Ранг, коллинеарность, численное решение **6**

9 Шум, правдоподобие, Гаусс–Марков **6**

9.1 Две модели ошибки 6

9.2 Что именно утверждает теорема 7

10 Коэффициент **7**

11 Метрики **7**

11.1 Две роли 8

11.2 Абсолютные 8

11.3 Относительные и их смещение 8

11.4 Квантиль и Хьюбер 9

11.5 Логарифм ответа 9

12 Где решают уравнение **9**

13 Шпаргалка: частые ошибки **10**

14 Откуда взяты идеи **11**

15 Памятка по слайдам **11**

1. Педагогическая цель и маршрут

После занятия студент должен без подсказки: (1) записать прогноз как Xw со столбцом единиц; (2) отличить линейность по весам от линейности по сырому признаку; (3) вывести формулы наклона и сдвига для одного признака и записать нормальные уравнения; (4) объяснить, что остаток ортогонален столбцам, а при копиях столбцов единственен прогноз, не вес; (5) связать квадрат с гауссовым шумом, модуль с лапласовым и назвать четыре условия Гаусса–Маркова; (6) выбрать метрику из MSE, RMSE, MAE, R^2, MAPE, sMAPE, RMSLE, pinball и Huber и назвать её ловушку; (7) посчитать эти числа на учебном примере и не назвать train-R^2 качеством; (8) решить уравнение только на train и узнать утечку в матрице X.

Это не лекция про градиентный спуск, KNN, полиномы и регуляризацию. Если спрашивают, как искать минимум, когда систему не решают, ответ один: неделя 4 даст шаг, неделя 5 применит его к этой же MSE.

Время	Слайды	Смысл и действие преподавателя
0–6 мин	1–2	Первый алгоритм с точным ответом. Качество — не арифметика на тех же точках.
6–18 мин	3–6	Модель, столбец единиц, линейность по w, сумма квадратов как функция весов.
18–40 мин	7–9	Вывод прямой на доске, нормальные уравнения, три точки.
40–52 мин	10–11	Проекция в $\mathbb{R}^n$, ранг, обусловленность, SVD вместо обратной матрицы.
52–62 мин	12–14	Гаусс и Лаплас, Гаусс–Марков, чтение коэффициента. Слайды 13–14 сжимаются первыми.
62–80 мин	15–19	Loss и метрика, абсолютные и относительные метрики, квантиль, Хьюбер, логарифм ответа.
80–90 мин	20–27	Train-таблица, split, утечка, вопрос, собеседование, практика.

Если обсуждение затягивается, теорему Гаусса–Маркова оставьте четырьмя именами условий, а слайд про $\exp(x^\top w)$ — одной оговоркой. Не сокращайте вывод наклона, нормальные уравнения, три точки и запрет выбора по test.

2. Гальтон и имя метода

6–15 мин

Слово **регрессия** в этом смысле ввёл Фрэнсис Гальтон. В 1885–1886 годах он сопоставил рост родителей и взрослых детей. Женский рост приводил к мужской шкале множителем около $1{,}08$ и усреднял двух родителей: *mid-parent*. Статья: Galton, *Regression towards mediocrity in hereditary stature*, Journal of the Anthropological Institute, 15 (1886).

Крайние родители дают детей ближе к середине популяции. Очень высокие отцы имеют высоких сыновей, но в среднем ниже себя. Очень низкие — низких сыновей, но в среднем выше себя. Гальтон назвал это возвратом к посредственности, *regression towards mediocrity*.

На график он наносил не отдельные семьи, а средний рост сыновей в группе с данным ростом родителей. Эти средние легли почти на прямую, более пологую, чем $45°$. Наклон у него был около $2/3$: отклонение родителей переходит сыну не целиком.

Современная запись при одинаковом разбросе x и y:

$$\mathbb{E}[y \mid x] = \mu + \beta(x - \mu), \qquad \beta = \rho.$$

Пока $|\rho| < 1$, предсказанное отклонение меньше отклонения x. Это и есть регрессия к сред-

нему. Если дисперсии разные,

$$\beta = \rho \frac{\sigma_y}{\sigma_x},$$

и наклон бывает больше единицы. Бытовой «откат» требует $0 < \beta < 1$.

Это не сила, которая тянет конкретного человека к норме. Шум, который сделал родителя крайним, детям не передаётся, поэтому группа, отобранная как крайняя, в следующем измерении ближе к середине. Тот же артефакт без биологии: худшие по первой контрольной на второй в среднем ближе к общей середине, даже если вмешательства не было. Сдвиг нельзя приписывать лечению.

Чего не говорить

Метод наименьших квадратов Гальтон не вывел и Пирсон не вывел. Его опубликовал Лежандр в 1805 году; Гаусс применял его раньше. Пирсон в 1896 году записал коэффициент корреляции как формальный объект. Имя *regression* принадлежит картинке Гальтона. Прямая, которую мы ищем сегодня, — уже задача МНК для условных средних, а не биологический закон.

3. Модель

6–18 мин

Прогноз на одном объекте:

$$\hat{y} = w_0 + w_1 x_1 + \cdots + w_d x_d.$$

В векторной записи к признакам дописывают единицу, $x = (1, x_1, \ldots, x_d)^\top$, и тогда $\hat{y} = w^\top x$. На матрице из n объектов $\hat{y} = Xw$. Первый столбец X состоит из единиц и отвечает за сдвиг. Без него прямая обязана проходить через начало координат: это содержательный запрет, его не включают молча. `sklearn.linear_model.LinearRegression` добавляет столбец сам при `fit_intercept=True`, это значение по умолчанию.

Линейность здесь — по весам. Запись $w_0 + w_1 x + w_2 x^2$ остаётся линейной моделью: столбцы равны 1, x, x^2, веса входят в первой степени, функция $Q(w)$ по-прежнему квадратична и выпукла. Запись $w_0 + e^{w_1} x$ линейной в этом смысле не является: нормальные уравнения для неё не написать. Полиномиальные столбцы и штраф за большие веса — неделя 6. Сегодня достаточно развилки.

Функция, которую минимизируют на train:

$$Q(w) = \|y - Xw\|^2 = \sum_{i=1}^{n} (y_i - x_i^\top w)^2.$$

Множитель $1/n$ или $1/2$ не меняет аргминимум. Он меняет только шкалу числа, которое называют loss. Ошибки 1 и 3 входят как 1 и 9.

Что спросить

Где в X живёт сдвиг? Останется ли модель линейной по весам, если вторым столбцом положить квадрат площади?

4. Вывод для одного признака

18–26 мин

Пишите на доске, слайд только фиксирует ответ. Для $\hat{y} = a + bx$

$$Q(a, b) = \sum_{i=1}^{n} (y_i - a - bx_i)^2.$$

Производная по сдвигу:

$$\frac{\partial Q}{\partial a} = -2 \sum_{i=1}^{n} (y_i - a - bx_i).$$

Ноль даёт $\sum(y_i - a - bx_i) = 0$, то есть $a = \bar{y} - b\bar{x}$. Прямая проходит через точку $(\bar{x}, \bar{y})$.

Производная по наклону:

$$\frac{\partial Q}{\partial b} = -2 \sum_{i=1}^{n} x_i (y_i - a - bx_i).$$

Подставьте $a = \bar{y} - b\bar{x}$:

$$\sum_{i=1}^{n} x_i \big((y_i - \bar{y}) - b(x_i - \bar{x}) \big) = 0.$$

Перенос b и тождество $\sum x_i(x_i - \bar{x}) = \sum (x_i - \bar{x})^2$ (потому что $\sum (x_i - \bar{x}) = 0$) дают

$$b = \frac{\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n} (x_i - \bar{x})^2}, \qquad a = \bar{y} - b\bar{x}.$$

Наклон — выборочная сонаправленность, делённая на выборочный разброс x. Делитель n или $n - 1$ сокращается, если он один и тот же в числителе и знаменателе.

Частный случай без признака, один столбец единиц: наклону не из чего взяться, и $a = \bar{y}$. Поэтому для MSE лучшая константа — среднее train. Для модуля производная в нуле ломается. Сдвиг константы на малый шаг уменьшает сумму модулей с одной стороны и увеличивает с другой; баланс — когда слева и справа объектов поровну. Это медиана. Замкнутой формулы наклона для модуля нет.

Не смешать с первой лекцией

На первой паре среднее было простым baseline для цены. Сегодня оно — решение нормальных уравнений в модели из одного столбца. Какая константа лучшая, зависит от критерия. Для MAE честнее медиана. Среднее остаётся законным baseline, если в таблице так и написано, а не сказано «оптимум модуля».

5. Нормальные уравнения

26–34 мин

Остаток $r = y - Xw$. Дифференцирование $Q(w) = r^\top r$ по вектору весов даёт

$$\nabla Q(w) = -2X^\top (y - Xw).$$

Критическая точка:

$$X^\top (y - Xw) = 0 \qquad \Leftrightarrow \qquad X^\top X\, w = X^\top y.$$

Это и есть нормальные уравнения. Явная запись $w = (X^\top X)^{-1} X^\top y$ требует полного столбцового ранга. На слайде её нет специально: обращать матрицу — плохой численный рецепт, см. раздел про ранг.

Гессиан равен $2X^\top X$. Для любого шага d

$$d^\top(2X^\top X)d = 2\|Xd\|^2 \geq 0.$$

Матрица положительно полуопределена, седла нет, критическая точка — глобальный минимум. Если ранг неполный, минимумов много, но вектор прогнозов Xw у них один: это проекция y на пространство столбцов.

6. Три точки

Признак $1, 2, 3$, ответы $1, 2, 2$. Тогда $\bar{x} = 2$, $\bar{y} = 5/3$. Отклонения x: $-1, 0, 1$. Отклонения y: $-2/3,\ 1/3,\ 1/3$.

$$b = \frac{(-1)(-2/3) + (1)(1/3)}{1+1} = \frac{1}{2}, \qquad a = \frac{5}{3} - 1 = \frac{2}{3}.$$

Прогнозы: $7/6,\ 5/3,\ 13/6$. Остатки: $-1/6,\ +1/3,\ -1/6$. Сумма остатков равна нулю — следствие столбца единиц, а не удачного примера. RSS $= 1/6$.

Среднее $5/3$ как отдельная модель:

$$\text{SST} = \left(-\frac{2}{3}\right)^2 + \left(\frac{1}{3}\right)^2 + \left(\frac{1}{3}\right)^2 = \frac{2}{3}.$$

На этих же трёх точках, с делителем $n = 3$:

	Только среднее	Прямая МНК
MSE	$2/9$	$1/18$
MAE	$4/9$	$2/9$
R^2	0	$3/4$
MAPE	$1/3$	$5/36$

$R^2 = 1-(1/6)/(2/3) = 3/4$. Прямая обязана выиграть у среднего по MSE на train: столбец единиц уже был в более узкой модели, пространство столбцов расширили. По MAE выигрыш в этом примере есть, но МНК его не гарантирует: веса искали не модулем. Все четыре строки — арифметика обучения. Качеством их не называют.

7. Геометрия

40–46 мин

Условие $X^\top(y - X\hat{w}) = 0$ означает: остаток ортогонален каждому столбцу X. Картинка на плоскости (x, y) — другой объект, чем эта формула. Формула живёт в $\mathbb{R}^n$, где y — один вектор, а столбцы X натягивают подпространство размерности не выше числа столбцов. МНК кладёт прогноз в это подпространство так, чтобы перпендикуляр из y был кратчайшим.

Если столбец единиц есть, остаток ортогонален и ему, поэтому сумма остатков нулевая. Теорема Пифагора для центрированного ответа, а не для сырого y:

$$\|y - \bar{y}\mathbf{1}\|^2 = \|X\hat{w} - \bar{y}\mathbf{1}\|^2 + \|y - X\hat{w}\|^2.$$

R^2 — доля первого слагаемого справа в левой части. Это доля объяснённой суммы квадратов отклонений от среднего. Не доля верных ответов, не вероятность и не «точность 75%».

Какое среднее стоит в знаменателе

На train при столбце единиц знаменатель — сумма квадратов отклонений от среднего train, и для константной модели $R^2 = 0$. Функция `sklearn.metrics.r2_score` по умолчанию берёт среднее того y, который передали. Если передали y_{test}, знаменатель живёт на test. Статья 3.2 учебника Яндекса советует константу-ориентир для MSE считать по train, чтобы не подглядывать. Это разные процедуры. На паре скажите о расхождении один раз.

8. Ранг, коллинеарность, численное решение

46–52 мин

Если два столбца совпали, $X^\top X$ необратима. Семейство w, дающих один и тот же Xw, бесконечно: к решению можно прибавить вектор из ядра X. Прогнозы на объектах, которые лежат в линейной оболочке обучающих строк, от выбора представителя не зависят. Рассказ «этот вес — рубли за метр» зависит и поэтому запрещён.

Почти зависимые столбцы формально оставляют единственного w, но делают его шумным. При сферических ошибках и полном ранге

$$\operatorname{Var}(\hat{w}) = \sigma^2 (X^\top X)^{-1}.$$

Малое собственное число $X^\top X$ раздувает дисперсию соответствующих комбинаций весов. Точечный прогноз $X\hat{w}$ при этом может почти не сдвинуться: неустойчив рассказ про отдельный коэффициент, а не обязательно линия. Площадь и число комнат в одном уравнении — бытовой пример. Коэффициент «за метр» не произносят отдельно от «за комнату».

Численно обращать $X^\top X$ не следует. Число обусловленности $X^\top X$ примерно квадрат числа обусловленности X, и погрешность входа усиливается дважды. Взрослые реализации решают задачу наименьших квадратов через QR или SVD. `LinearRegression` в scikit-learn идёт этим путём и среди равных по остатку решений берёт веса минимальной нормы. Регуляризация, которая лечит почти-копии добавкой λI, — неделя 6. Сегодня дыру называют.

9. Шум, правдоподобие, Гаусс–Марков

52–62 мин

9.1. Две модели ошибки

Пусть $y = Xw + \varepsilon$ и координаты ε независимы, $\mathcal{N}(0, \sigma^2)$. Плотность выборки пропорциональна

$$\exp\bigl(-\|y - Xw\|^2 / (2\sigma^2)\bigr).$$

Максимум правдоподобия по w совпадает с минимумом квадратов. Оценка σ^2 по максимуму правдоподобия равна RSS/n. Несмещённая оценка при полном ранге и p столбцах — $\mathrm{RSS}/(n-p)$. На паре хватает одной фразы: делитель зависит от соглашения, аргминимум по w от него не зависит. Это тот же жест, что с n и $n-1$ в дисперсии.

У распределения Лапласа плотность пропорциональна $\exp(-|y_i - x_i^\top w|/b)$. Максимум правдоподобия совпадает с минимумом модуля. Для одной константы оптимум — медиана. В общем случае замкнутой линейной системы нет; задачу решают как линейную программу.

Квадрат тянет прямую к далёкой точке, потому что её вклад растёт как квадрат расстояния. Модуль растёт линейно и смотрит скорее на то, по какую сторону остатка лежит большинство точек.

9.2. Что именно утверждает теорема

При четырёх условиях оценка МНК — лучшая линейная несмещённая оценка w (*best linear unbiased estimator*). «Лучшая» значит: минимальная дисперсия среди оценок, которые линейны по y и несмещены. Не среди всех мыслимых оценок.

1. Спецификация: $\mathbb{E}[y \mid X] = Xw$. Среднее и правда лежит в выбранных столбцах.
2. Экзогенность: $\mathbb{E}[\varepsilon \mid X] = 0$. Признаки не несут остаточной связи с ошибкой.
3. Сферичность: $\mathrm{Var}(\varepsilon \mid X) = \sigma^2 I$. Дисперсия одна и та же, ошибки не коррелируют друг с другом.
4. Полный столбцовый ранг. Иначе отдельный вес не идентифицирован.

Гауссов шум в этот список не входит. Он нужен, чтобы МНК совпал с максимумом правдоподобия и чтобы точные интервалы Стьюдента имели названное распределение. Для BLUE хватает четырёх пунктов выше.

Гетероскедастичность ломает сферичность. При сохранённой экзогенности веса часто остаются несмещёнными и перестают быть эффективными; обычные стандартные ошибки, посчитанные как $\sigma^2(X^\top X)^{-1}$, врут. Эндогенность ломает второй пункт: пропущенный признак, который сидит и в столбце, и в ошибке, смещает веса. Это уже не «шум в ответе», а другая задача. Теорема не выдаёт причинность.

Если осталось сорок секунд

Назовите четыре условия и одну поломку: веер дисперсии не обязан сместить прямую, но лишает МНК звания лучшей линейной несмещённой оценки. Пропущенный общий фактор смещает.

10. Коэффициент

Фраза, которую можно произнести: при прочих равных столбцах модели плюс одна единица признака j сдвигает прогноз на w_j.

Фраза, которую произнести нельзя: признак причиняет ответ; вес устойчив, хотя столбцы ходят вместе; после стандартизации w_j всё ещё измерен в рублях за метр. Стандартизованный столбец меняет единицу: вес относится к одному стандартному отклонению. Дамми района — разница прогноза относительно того уровня, которого в столбцах нет, а не «вклад района вообще».

11. Метрики

62–80 мин

11.1. Две роли

Функция потерь даёт число, по которому на train ищут w. **Метрика** отвечает, насколько прогноз полезен для решения, и её считают на строках, не участвовавших в этом поиске. Учить MSE и сообщать MAE — нормальная пара. Совпадение формулы роли не сливает.

11.2. Абсолютные

$$\mathrm{MSE} = \frac{1}{m}\sum_{j=1}^{m}(y_j - \hat{y}_j)^2, \qquad \mathrm{RMSE} = \sqrt{\mathrm{MSE}}, \qquad \mathrm{MAE} = \frac{1}{m}\sum_{j=1}^{m}|y_j - \hat{y}_j|.$$

RMSE возвращает единицы y, но крупные ошибки по-прежнему входят через квадрат. Лучшая константа MSE — среднее, лучшая константа MAE — медиана.

$$R^2 = 1 - \frac{\sum(y_j - \hat{y}_j)^2}{\sum(y_j - \bar{y})^2}.$$

Единица — совпадение с ответами. Ноль — не лучше константы среднего в выбранной записи. Отрицательное значение на новых данных — хуже этой константы.

Скорректированный коэффициент на той же выборке,

$$R^2_{\mathrm{adj}} = 1 - (1 - R^2)\frac{n-1}{n-p},$$

уменьшает долю за лишние столбцы. Это штраф на train, а не замена validation. Сравнивать им модели с разным преобразованием y нельзя: знаменатель живёт в другой шкале.

11.3. Относительные и их смещение

$$\mathrm{MAPE} = \frac{1}{m}\sum_{j=1}^{m}\frac{|y_j - \hat{y}_j|}{|y_j|}.$$

На одной точке ошибка «вдвое выше» и «вдвое ниже» даёт один и тот же MAPE. По набору разных y это уже не так. Для константы c субградиент суммы $|y_i - c|/|y_i|$ уравновешен, когда сумма весов $1/|y|$ слева от c равна сумме справа. Оптимум — взвешенная медиана с весами $1/|y|$. Большой ответ весит меньше, константа тянется к меньшим y. При $y = 0$ метрика не определена. Отрицательные ответы требуют отдельной договорённости, которой у обычного MAPE нет.

sMAPE делит модуль на $|y|+|\hat{y}|$ (часто ещё с множителем 2). Слово «симметричная» описывает формулу, не оптимум. При фиксированном модуле ошибки больший прогноз увеличивает знаменатель и уменьшает штраф, поэтому оптимум снова съезжает вниз.

$$\mathrm{RMSLE} = \sqrt{\frac{1}{m}\sum_{j=1}^{m}\big(\log(1 + y_j) - \log(1 + \hat{y}_j)\big)^2}.$$

Метрика сравнивает порядки. При ответе 100 прогноз 50 даёт больший логарифмический зазор, чем прогноз 150: при том же модуле занижение весит больше завышения. Отрицательный y в $\log(1 + y)$ не подставить.

11.4. Квантиль и Хьюбер

Pinball-потеря уровня $\tau \in (0, 1)$:

$$\rho_\tau(r) = \begin{cases} \tau r, & r \geq 0, \\ (\tau - 1)r, & r < 0. \end{cases}$$

При $\tau = 1/2$ это $|r|/2$, и константа-оптимум — медиана. В общем случае минимум ожидаемого pinball по константе — квантиль уровня τ: субградиент меняет знак, когда доля точек слева достигает τ. Если недопрогноз дороже перепрогноза, берут $\tau > 1/2$. Это уже функция потерь под асимметричное решение, не ещё один синоним MAE.

Хьюбер с порогом $\delta > 0$: квадрат при $|r| \leq \delta$ и линейный рост дальше,

$$H_\delta(r) = \begin{cases} \frac{1}{2} r^2, & |r| \leq \delta, \\ \delta(|r| - \delta/2), & |r| > \delta. \end{cases}$$

В нуле функция гладкая, в отличие от модуля, и хвост не получает квадратичного голоса. Это loss для обучения. В отчёт бизнесу её не кладут. δ выбирают по validation; на test порог не крутят.

11.5. Логарифм ответа

Если учат $\log y = x^\top w + \varepsilon$ при $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ и $y > 0$, то условное распределение y логнормально. Его медиана равна $\exp(x^\top w)$, а среднее —

$$\mathbb{E}[y \mid x] = \exp(x^\top w + \sigma^2/2).$$

Поправка $\sigma^2/2$ принадлежит этой модели шума. Её не ставят универсальным коэффициентом «чтобы перевести логарифм в рубли». Неравенство Йенсена объясняет направление без нормальности: exp выпукла, поэтому среднее $\exp(\varepsilon)$ больше единицы, если $\mathbb{E}\varepsilon = 0$ и ε не постоянно. Метрика в логарифме и метрика в рублях отвечают на разные вопросы. В таблице эксперимента единица измерения написана явно, иначе строка с $\log y$ побеждает строку в рублях видом числа.

12. Где решают уравнение

80–90 мин

- **Train** — столбцы, веса, среднее константы, μ и σ любых преобразований.
- **Validation** — какой набор столбцов оставить, какую метрику отчёта выбрать, какой δ у Хьюбера.
- **Test** — один отчёт уже выбранного решения.

Случайный `train_test_split` честен, только если строки независимы и одинаково устроены. Время не перемешивают: будущая цена не проверяется перемешанным будущим. Одна сущность не стоит по обе стороны split. `random_state` фиксируют. k-fold на этой паре не открывают.

Утечка здесь — конкретная поломка матрицы, а не общий лозунг. Три дыры практики:

1. **Прокси ответа.** Цена за метр, умноженная на площадь, восстанавливает цену. Нормальные уравнения найдут почти нулевой остаток и пустые веса.
2. **Статистика до split.** Среднее для заполнения пропуска, μ и σ масштаба, словарь категорий оценивают на train и затем применяют к остальным частям:

$$z = \frac{x - \mu_{\text{train}}}{\sigma_{\text{train}}}.$$

   На train значения $0, 0, 10$, на test значение 10. $\mu_{\text{train}} = 10/3$, среднее всех четырёх точек равно 5. Отложенный объект уже вошёл в преобразование.
3. **Одна сущность дважды.** Кадры одного видео, сделки одного дома, один человек в train и test. Модель запоминает сущность. Тот же механизм у случайного split по времени.

Высокий score — повод проверить список, не доказательство дыры и не доказательство качества.

Таблица эксперимента — одна строка на законченный протокол. На validation из отдельного, не досочного примера истинные цены 6 и 14, константа train равна 10 и даёт MAE 4; прямая даёт прогнозы 7 и 13, MAE 1. Двух точек мало, чтобы объявить модель годной. Третью строку, где масштаб посчитан по всей матрице, рядом не ставят: у неё другой протокол.

Три финальных вопроса

1. Какая константа минимизирует MSE, и из какого частного случая нормальных уравнений она берётся?
2. Почему совпавшие столбцы убивают рассказ про вес, но не обязательно прогноз?
3. Чем MAPE отличается от MAE, кроме деления на y?

Ответы: среднее, потому что в модели из столбца единиц критическая точка — $\bar{y}_{\text{train}}$; прогнозы — проекция на пространство столбцов, и прибавление вектора из ядра X её не меняет; MAPE не определена при нуле и тянет константу к меньшим ответам как взвешенную медиану с весами $1/|y|$.

Вопрос собеседования: R^2 на train равен $0{,}98$, хороша ли модель. Сильный ответ отказывается. Train-R^2 растёт от добавления столбцов; число ничего не говорит ни о новых объектах, ни о том, совпадает ли метрика с решением, ни о копиях столбцов и прокси ответа внутри X. Слабый ответ: «это 98% точности».

13. Шпаргалка: частые ошибки

Неверное утверждение	Что ответить
«Квадрат признака выводит модель из линейных»	По весам она остаётся линейной. Ломает линейность вес внутри функции.
«Делим на n или на $n-1$ — получим другие веса»	Для аргминимума квадрата множитель не важен. Делитель важен для оценки σ^2.
«Всегда пишем $w = (X^\top X)^{-1} X^\top y$»	Это формула при полном ранге. Считают через QR или SVD.
«Коллинеарность портит прогнозы, значит и веса»	Часто наоборот: веса разъезжаются, проекция остаётся устойчивой.
«$R^2 = 0{,}75$ — точность 75%»	Доля объяснённых квадратов против выбранной константы.
«MAPE симметрична, раз в названии нет квадрата»	На разных y оптимум смещён к меньшим ответам. При нуле метрики нет.

Неверное утверждение	Что ответить
«sMAPE чинит смещение MAPE»	Знаменатель растёт вместе с прогнозом, оптимум снова съезжает вниз.
«exp от логарифмического прогноза — ожидаемая цена»	Для нормального шума в логарифме это медиана. Среднее больше на $\exp(\sigma^2/2)$.
«Гаусс–Марков требует нормальных ошибок»	Нормальность нужна для ММП. Для BLUE нужны спецификация, экзогенность, сферичность и ранг.
«Высокий R^2 доказывает отсутствие утечки»	Он совместим и с прокси ответа, и с одной сущностью по обе стороны split.

14. Откуда взяты идеи

Оценка качества и запрет смешивать выборки собраны по программе курса и по статьям учебника Яндекса, без переноса их текста:

- 1.3. Машинное обучение: выбор метрики под цель, запрет смешивать train и test.
- 3.1. Введение в оценку качества: метрика как критерий сравнения; важно, на каких объектах она посчитана.
- 3.2. Метрики: функция потерь и метрика; MSE, RMSE, R^2 относительно константы; MAE при хвостах.
- 3.3. Кросс-валидация: hold-out, shuffle, прокси ответа, статистики до split, группы и время.

Устройство МНК — стандартный контур курса линейных моделей ВШЭ (Е. А. Соколов) и главы 3 *The Elements of Statistical Learning*: нормальные уравнения, проекция остатка, выпуклость квадрата, различие замкнутой формы и итеративного поиска. Теорема Гаусса–Маркова названа в своей классической границе, без обещания причинности. На этой паре не выводим k-fold, градиентный шаг, Ridge и метрики классификации.

15. Памятка по слайдам

№	Слайд	Переход
1	Линейная регрессия	KNN, спуск и Ridge не обещать.
2	Откуда берутся веса	Пример 1, 2, 2 при $x = 1, 2, 3$ назван заранее.
3	Взвешенная сумма	Единица уже внутри x, если есть сдвиг.
4	Столбец единиц	Без него прямая проходит через ноль.
5	Линейность по весам	x^2 можно, e^w нельзя.
6	Сумма квадратов	$1/n$ не двигает минимум.
7	Формулы a и b	Вывод на доске. Константа — среднее.
8	Нормальные уравнения	Градиент, гессиан, единственность при полном ранге.
9	Три точки	$a = 2/3$, $b = 1/2$, сумма остатков нулевая.
10	Ортогональность	Пифагор для центрированного y. R^2 — не точность.
11	Ранг	Прогноз единственен, вес нет. SVD, не обратная матрица.
12	Гаусс и Лаплас	ММП. Делитель σ^2 — одна фраза.
13	Гаусс–Марков	Четыре условия. Нормальность не входит. Можно сжать.
14	Чтение w_j	При прочих равных в модели. Не причина.
15	Loss и метрика	Учить MSE, сообщать MAE.
16	MSE, RMSE, MAE, R^2	Adjusted — штраф на train. Оговорить sklearn.
17	MAPE, sMAPE, RMSLE	Каждая смещает оптимум по-своему.
18	Pinball и Хьюбер	$\tau = 1/2$ — медиана. δ только по validation.
19	Логарифм ответа	$\exp(x^\top w)$ — медиана. Можно свернуть.
20	Таблица на трёх точках	Train. По MSE прямая обязана выиграть.

№	Слайд	Переход
21	Три роли	Время, группа, запрет правки по test.
22	Три дыры	Прокси, статистика, сущность. $\mu = 10/3$ против 5.
23	Строка эксперимента	6 и 14 — другой пример. Третью строку не сравнивать.
24	Какое утверждение верно	Ответ Б.
25	$R^2 = 0{,}98$	Дождаться отказа и двух слоёв аргумента.
26	Практика	Руки, sklearn, четыре метрики, утечка, таблица.
27	Итог	Три вопроса из раздела про split.